ETL
Proyecto Final Entrega 2
Informe de Avance: Análisis y preparación de los datos

Presentado Por:
Esteban Urueña Sanmiguel

Presentado a:
Fernando Barraza Alvarado

UNIVERSIDAD AUTONOMA DE OCCIDENTE
Maestría en Inteligencia Artificial y Ciencia de Datos

Este informe continúa el proyecto de la Entrega 1: construir, a partir de cuatro extracciones de SAP (ME2N, ME5K, MSRV5 y MB51), un conjunto de datos confiable del costo real de cambiar o instalar postes y transformadores bajo el contrato con el COR, como insumo para proyectar el presupuesto de inversión del año siguiente. Se presentan el análisis exploratorio (EDA), la evaluación de calidad con el modelo de las V's, su impacto sobre el problema y las transformaciones que se derivan de esos hallazgos. **Por confidencialidad, las cifras monetarias se presentan en términos relativos** (porcentaje del total o múltiplos del costo mediano por solped), de acuerdo con la condición de uso de los datos definida en la Entrega 1.

1. Análisis Exploratorio de Datos (EDA)

1.1 Estructura de las fuentes

Fuente	Contenido	Registros	Periodo	Llaves y nulos relevantes
ME2N	Pedidos de los 2 contratos marco del COR	6.756 líneas · 352 pedidos	29-dic-2025 a 31-ago-2026	Pedido. Indicador de borrado 100 % vacío
ME5K	Solicitudes de pedido (solped) de cada pedido: OM, valor neto, fecha de pedido	7.639 líneas · 6.751 solped · 6.643 OM	29-dic-2025 a 31-ago-2026	Solped, OM, Pedido. 8 filas sin OM válida (0,1 %); Centro de coste y PEP 100 % vacíos
MSRV5	Detalle de servicios de las solped, filtrado a 19 códigos de poste/trafo	1.041 líneas · 977 solped	24-sep-2025 a 11-ago-2026 (creación solped)	Solped. Sin nulos
MB51	Movimientos de material (261 salida, 262 retorno) por OM	18.451 movimientos · 957 OM · 250 materiales	4-nov-2025 a 25-ago-2026	OM. 4 columnas 100 % vacías; clase de valoración 17,9 %

La información sigue una cadena de documentos: **pedido → solped y OM → servicios de la solped → material de la OM**. Las cuatro fuentes tienen granularidades distintas: el valor del servicio está a nivel de solped (ME5K), el detalle a nivel de línea de servicio (MSRV5) y el material a nivel de OM (MB51). La integridad referencial es alta: el 100 % de las solped de MSRV5 existe en ME5K, ninguna solped tiene más de una OM. Se identificaron casos especiales los cuales son: 3 solped sin OM válida, 1 OM compartida por 2 solped facturadas en pedidos distintos y 16 solped cuya OM no tiene movimientos en MB51; al validarlas con el área se confirmó que su material se pagó con otras OM, por lo que su costo está incompleto.

1.2 Servicios, composición de las solped y material

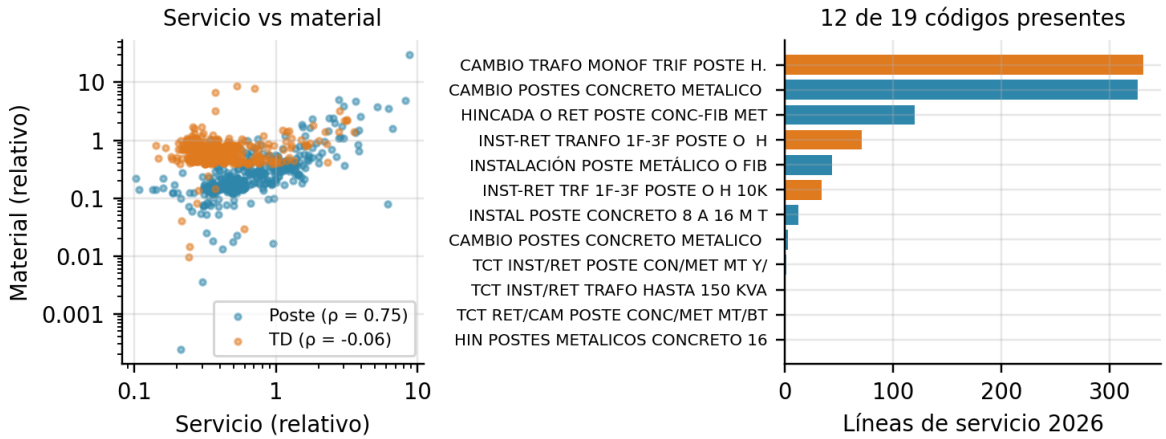


Figura 1. Izquierda: relación servicio–material por solped (escala log, valores relativos a la mediana). Derecha: frecuencia de los códigos de servicio en 2026.

Solo **12 de los 19 códigos** del filtro aparecen en 2026, y dos concentran el 69 % de las líneas (cambio de trafo y cambio de poste de concreto/metálico rural). De las 887 solped de 2026, 830 tienen un único servicio, 54 tienen dos y 3 tienen tres; 33 solped mezclan servicios de poste y de trafo. Este punto es crítico: el valor

del pedido es de la solped completa, de modo que cada línea adicional de servicio repite el valor si se suma línea a línea.

En MB51 los retornos de material (262) equivalen apenas al **1,0 %** del valor de las salidas de material (261), y 10 materiales concentran el 54,5 % del material consumido. El material pesa el 33,4 % del costo en Poste y el 60,1 % en TD (Transformador de Distribución). En Poste, servicio y material crecen juntos (Spearman ρ = 0,75), mientras que en TD no hay relación (ρ = −0,06): el costo del transformador depende del equipo instalado y no del valor del servicio. Por eso los dos componentes deben analizarse por separado.

1.3 Costo por solped: distribución y valores atípicos

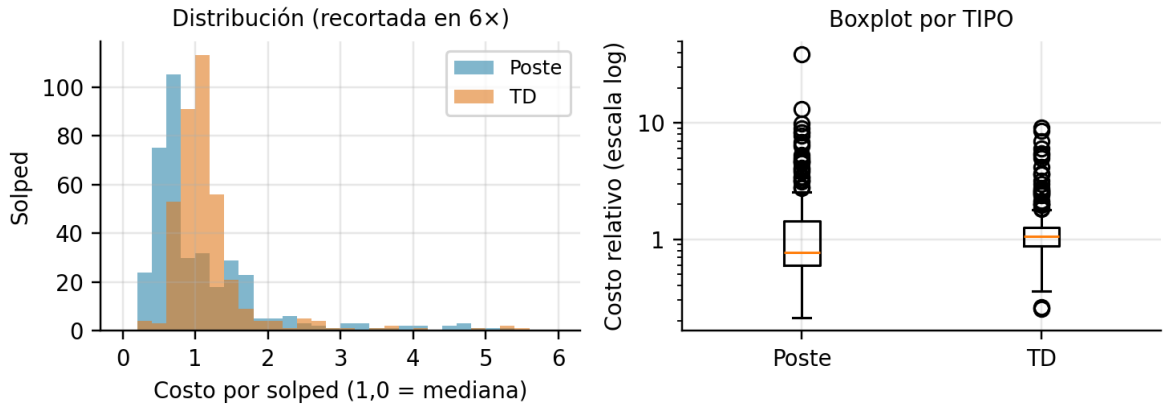


Figura 2. Distribución del costo total por solped (1,0 = mediana de la base ene–jun) y boxplot por TIPO en escala logarítmica.

TIPO – Centro	Solped	% del costo de la base	Mediana (× mediana global)	Coeficiente de variación
Poste – 1315	186	22,0 %	0,69	1,22
Poste – 1316	202	30,8 %	0,92	1,93
TD – 1315	179	19,7 %	1,01	0,59
TD – 1316	203	27,5 %	1,09	0,80

La distribución es fuertemente asimétrica a la derecha (asimetría de 10,8 en Poste y 5,0 en TD). Con la regla IQR, 33 solped de Poste y 32 de TD son atípicas y concentran el 38,2 % y el 23,9 % del costo de cada tipo. La solped de mayor valor equivale a 38,6 veces la mediana, representa el 3,8 % del costo de la base y el 12 % del costo de marzo, y su material es 3,4 veces su servicio; al validarla con el área se confirmó que corresponde a una obra grande, es decir, es un caso real y no un error. El centro 1316 es más costoso y más variable que el 1315 en ambos tipos. En cambio, el costo por unidad de servicio (costo total / cantidad de servicios) es mucho más estable: coeficiente de variación de 0,52 en Poste y 0,66 en TD, frente a 1,2–1,9 del costo por solped, lo que lo convierte en la variable candidata para el modelo.

1.4 Comportamiento temporal: ejecución vs. facturación

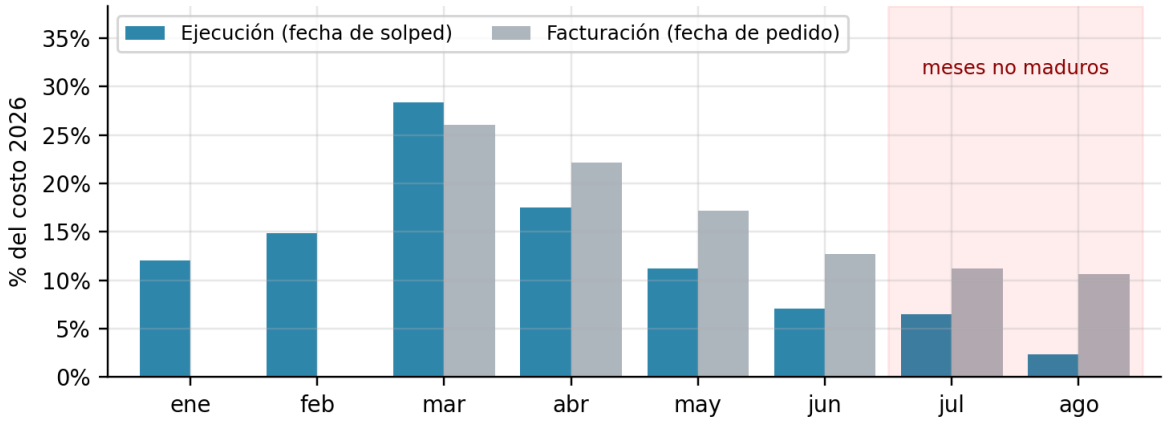


Figura 3. Costo mensual 2026 según la fecha usada para asignar el mes (porcentaje del costo total 2026).

Este es el hallazgo de mayor impacto. La fecha de creación de la solped se genera cuando se registran los servicios en la OM y está a una mediana de 5 días del primer movimiento de material, por lo que **representa la ejecución**. La fecha del pedido **representa la facturación**: con ella, enero y febrero quedan prácticamente en cero y marzo acumula lo ejecutado en los meses anteriores. Usar la fecha de pedido construiría una serie que refleja el ciclo de facturación del contratista y no el comportamiento real de la red.

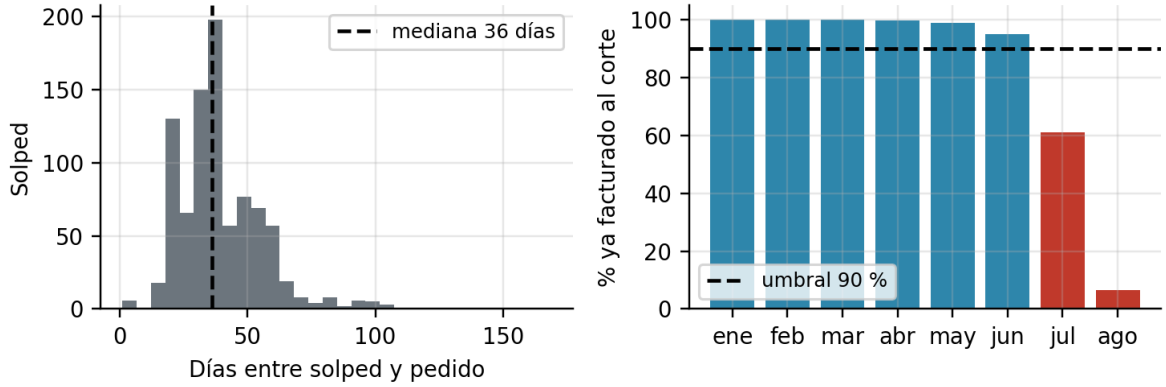


Figura 4. Izquierda: días entre la creación de la solped y el pedido. Derecha: completitud estimada de cada mes al corte de la extracción (31-ago-2026).

El rezago entre solped y pedido tiene una mediana de 36 días (media 39,7; máximo 169): el 21 % de las solped se factura en 30 días, el 87 % en 60 y el 97 % en 90. Como la población se extrae desde los pedidos creados hasta el 31 de agosto, las solped recientes aún no facturadas no aparecen. Aplicando la distribución del rezago observada en ene–mar a cada día de cada mes, la completitud estimada es ≥ 95 % de enero a junio, 61 % en julio y 7 % en agosto. La base confiable es, por tanto, enero–junio de 2026: 770 solped (388 Poste y 382 TD), con la siguiente distribución del costo: ene 13,3 %, feb 16,3 %, mar 31,2 %, abr 19,2 %, may 12,3 % y jun 7,8 %.

Hallazgos clave del EDA: (1) la fecha de pedido desplaza el costo hacia la facturación; (2) julio y agosto están incompletos por el rezago; (3) varias líneas por solped duplican valores si se suman línea a línea; (4) el costo por solped es muy asimétrico, con atípicos que pesan hasta el 38 % del costo; (5) servicio y material tienen comportamientos distintos por TIPO; (6) el costo por unidad de servicio es la variable más estable.

2. Análisis de Calidad de los Datos — Modelo de las V's

V	Relevancia	Diagnóstico basado en evidencia
Volume	Relevante	~34 mil registros en las 4 fuentes, pero tras integrar y depurar quedan 770 solped en 6 meses maduros para estimar costos unitarios, pero una serie mensual tendría solo 6 puntos: el modelo debe trabajar a nivel de solped, no de mes.
Variety	Media	Las 4 fuentes son tablas estructuradas de SAP, pero con granularidades (pedido, solped, línea de servicio, movimiento de material) y tipos de llave distintos (la OM llega como número con decimales o vacía). Exige normalización de llaves e integración; no hay datos no estructurados.
Velocity	Relevante	Extracción manual por lotes. El rezago de facturación (mediana 36 días) deja incompletos los meses recientes (julio 61 %, agosto 7 %). Una carga mensual por lotes es suficiente, siempre que incluya una regla de madurez de los meses.
Veracity	Muy relevante	El cálculo manual tenía errores verificados: material duplicado en 4 solped, material de una OM compartida contado dos veces, 2 solped con el valor en la línea equivocada (no sumadas), 3 solped sin OM y 16 solped cuyo material se pagó con otras OM (sin movimientos en MB51). La tabla dinámica original, al incluir las líneas "-", sumaba dos veces el valor de las solped mixtas.
Variability	Muy relevante	La forma de la serie cambia por completo según la fecha usada (enero: 13,3 % del costo con fecha de solped y 0 % con fecha de pedido). El costo por solped tiene asimetría de 10,9 en Poste y un coeficiente de variación de hasta 1,93 en Poste–1316, con diferencias sistemáticas entre centros y tipos.
Value	Relevante	Separar servicio y material y calcular el costo por unidad de servicio (CV 0,52–0,66) da una señal estable para estimar el presupuesto. El material explica el 60 % del costo en TD, por lo que omitirlo o duplicarlo sesga directamente la proyección.

3. Impacto de la Calidad sobre el Problema

Se concilió el cálculo manual del área contra la tabla construida con reglas automáticas. La diferencia se explicó al 100 % (residuo cero) con las siguientes causas:

Causa (ene–jun 2026, TIPO Poste/TD)	Efecto sobre el total	Tipo de error
Material duplicado en dos líneas clasificadas de la misma solped	−0,07 %	Sobreestimación
Material de una OM compartida contado en sus dos solped	−0,12 %	Sobreestimación
Solped mixta con todas sus líneas en "-" (no sumada)	+0,41 %	Subestimación
Valor de la solped en la línea "-" y la línea TD en 0	+0,08 %	Subestimación
Efecto neto sobre el total manual	**+0,29 %**	

En el total, los errores se compensan parcialmente y el efecto neto es pequeño, pero el riesgo real está en la distribución del costo, que es lo que alimenta la proyección. Si se usara la fecha de pedido, el 29,6 % del costo de la base, ejecutado en enero–febrero, aparecería en meses posteriores y se contarían en 2026 43 solped ejecutadas en septiembre–diciembre de 2025 (≈ 4,4 % del costo de la base). Si se incluyeran julio y agosto sin considerar su madurez, esos meses se subestimarían en cerca del 39 % y el 93 %, y un modelo interpretaría una caída de la actividad que no existe. Los atípicos, si se eliminan, borrarían eventos reales de alto costo; si se usan sin control, un solo caso puede mover el costo de un mes en un 12 %. Por último, las 16 solped cuyo material se pagó con otras OM tienen solo el costo del servicio: si se incluyeran, bajarían artificialmente el costo por solped y el peso del material.

4. Transformaciones Requeridas

Cada transformación responde a un hallazgo del EDA o del análisis de calidad. Todas están implementadas y validadas en el notebook.

- **Limpieza — OM válida:** se conservan solo las solped cuya OM inicia por "400"; se descartan 3 solped sin OM. Se eliminan las columnas vacías al 100 % y las columnas calculadas a mano en el Excel (TIPO, Valor Pedido, Valor Material), que se recalculan con reglas explícitas.
- **Normalización de llaves y tipos:** la OM se convierte a texto sin decimales en ME5K y MB51; las fechas y las clases de movimiento se tipifican.
- **Clasificación por regla:** cada código de servicio se mapea a Poste o Trafo (mapa fijo de los 19 códigos). Esto reemplaza la clasificación manual línea a línea.

- **Integración a una fila por solped:** se consolidan las líneas de MSRV5 por solped. TIPO = TD si la solped tiene algún servicio de trafo; si no, Poste. El valor de la solped se toma una sola vez, lo que elimina por diseño la doble suma.
- **Integración del material:** material de la OM = −(261 + 262) en MB51, sin filtro de fecha. Si una OM tiene varias solped, el material se reparte en proporción al valor del servicio de cada una.
- **Variables derivadas:** Valor_Servicio = valor neto ME5K × 1,19 (IVA); Valor_Material; Valor_Total; Rezago_dias (pedido − solped); Costo_unitario = Valor_Total / cantidad de servicios; n_poste y n_trafo por solped.
- **Asignación temporal y madurez:** el mes se toma de la fecha de creación de la solped (ejecución), no del pedido. Se calcula la completitud de cada mes con la distribución del rezago y solo entran al modelo los meses con completitud ≥ 90 % (ene–jun). Julio y agosto quedan marcados como no maduros y se incorporan cuando una nueva extracción los complete.
- **Datos faltantes:** se excluyen de la base las 16 solped cuya OM no tiene movimientos en MB51, porque el área confirmó que su material se pagó con otras OM y su costo está incompleto. Imputarles cero subestimaría el costo; el pipeline las reporta en cada ejecución.
- **Valores atípicos:** no se eliminan. Se marcan con la regla IQR por TIPO y se validan con el área los de mayor peso (la solped de mayor valor se confirmó como una obra grande). En el modelo se usan estadísticos robustos (mediana) o winsorización del costo unitario en el percentil 99, para acotar su efecto sin perder los eventos reales.
- **Validaciones automáticas y anonimización:** en cada ejecución se reportan las solped sin OM, las solped con más de un pedido, las OM compartidas, los servicios fuera del mapa y las solped sin material. Antes de publicar, los valores se multiplican por el factor de ajuste de confidencialidad. El ajuste por IPC se aplicará en la Entrega 3 sobre el costo ya consolidado.

5. Coherencia y Trazabilidad

Hallazgo (EDA / Calidad)	Impacto sobre el problema	Transformación asociada
Fecha de pedido = facturación; ene–feb en 0 y pico en marzo	Serie que refleja el ciclo de facturación, no la ejecución	Mes según la fecha de creación de la solped
Rezago de facturación de 36 días; jul 61 % y ago 7 % completos	Subestimación de los meses recientes; falsa tendencia a la baja	Completitud mensual y base solo con meses ≥ 90 %
Varias líneas de servicio por solped; 33 solped mixtas	Doble suma del valor de la solped	Una fila por solped y TIPO por regla (TD si hay trafo)
Clasificación y ceros manuales con errores (4 casos de material duplicado, 2 solped no sumadas)	Total y distribución por TIPO incorrectos	Mapa fijo de servicios y cálculo automático de valores
OM compartida por 2 solped	Material contado dos veces	Reparto proporcional del material de la OM
3 solped sin OM válida	Costo sin actividad de mantenimiento asociada	Filtro de OM que inicia por "400"
16 solped sin movimientos en MB51 (material pagado con otras OM)	Costo de la actividad incompleto; subestima el costo por solped	Exclusión de la base, validada con el área
Asimetría fuerte; atípicos con el 38 % del costo en Poste (casos reales)	Un caso puede mover el costo de un mes en 12 %	Marca IQR, validación con el área y estadísticos robustos / winsorización P99
Relación servicio–material distinta por TIPO; costo unitario estable	Un modelo único mezclaría dos comportamientos	Variables separadas por componente y costo unitario por TIPO